## Naive Bayes klasifikator

Za ocjenjivanje komentara i rečenica razdijeljenih na kategorije korištena je Naive Bayes metoda. To je jednostavna metoda strojnog učenja s vrlo čestom primjenom u klasifikacijskim problemima. Osnovna ideja je u određivanju vjerojatnosti pripadnosti rečenice nekoj kategoriji na temelju vjerojatnosti pojavljivanja određenih riječi u toj kategoriji.

Točnije, označimo sa c klase subjektivnosti i sa d rečenica koji proučavamo. Neka su  $f_1 \dots f_m$  atributi koji se pojavljuju u toj rečenici i neka je  $n_i(d)$  broj pojavljivanja atriburta  $f_i$  u rečenici d. Naive Bayes metoda računa vjerojatnost pripadnosti klasi c uz uvjet da proučavamo rečenicu d i traži c koji će maksimizirati danu vjerojatnost. Metoda koristi Bayesovo pravilo kako bi računala traženu uvjetnu vjerojatnost:

$$P(c|d) = \frac{P(d|c)P(c)}{P(d)}$$

Kako bismo to izračunali, koristimo pretpostavku uvjetne nezavisnosti atributa  $f_i$  uz klasu c kao uvjet. Ta pretpostavka očito ne vrijedi u stvarnom svijetu te je zbog tog pojednostavljenja metoda dobila naziv "naive". Koristeći tu pretpostavku, prethodna se formula pretvara u identitet čiju desnu stranu znamo izračunati.

## Ocjenjivanje

Kao što je opisano, Naive Bayes vraća vjerojatnosti pripadnosti svakoj kategoriji (koje u sumi daju 1). Te smo vjerojatnosti koristili za generiranje vlastitih ocjena po formuli:

$$ocjena = P(pozitivno) \times 5 + P(srednje) \times 3 + P(negativno) \times 1$$

S obzirom na to da smo pozitivne i negativne komentare određivali vrlo strogo (odnosno samo za vrlo polarizirane komentare), ovakav će način ocjenjivanja dati nešto veći raspon ocjena, što je i bio cilj s obzirom na to da su sve pive koje ocjenjujemo već vrlo dobre.

Kao razliku od korisničkih ocjena (ne u svrhu usporedbe s korisničkim ocjenama, već samo u svrhu provjere korektnosti algoritma) smo stoga promatrali standardnu kvadratnu pogrešku, koja je na nasumično generiranih 1000 komentara iznosila 0.3142.

Implementacija klase Naive Bayes nalazi se fileu bayes.py.